

Optimización Numérica: Laboratorio 5

rodrigo.mendoza@itam.mx

8 Octubre 2019

1 El Lemma de Johnson-Lindenstrauss

Supongamos que tenemos un conjunto de datos $\mathcal{D} = \{(\mathbf{x}_i, y_i) \in \mathbb{R}^n \times \mathbb{R} : i \in [m]\}$ y que n es *muy* grande. Queremos reducir la dimensionalidad de \mathcal{D} preservando la información geométrica en el conjunto de datos (esto es, preservar las distancias relativas $\|x_i - x_j\|$ entre los puntos de datos). En este laboratorio vamos a demostrar una versión del lemma de Johnson-Lindenstrauss.

Lemma 1 (Johnson-Lindenstrauss). *Para todo $\varepsilon \in (0, 1)$ y entero m , sea k un entero positivo tal que*

$$k \geq 4 \left(\frac{\varepsilon^2}{2} - \frac{\varepsilon^3}{3} \right)^{-1} \log m \quad (1)$$

Entonces, para todo $S = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathbb{R}^n$ existe $f : \mathbb{R}^n \rightarrow \mathbb{R}^k$ tal que

$$(1 - \varepsilon) \leq \|u - v\|^2 \leq \|f(u) - f(v)\|^2 \leq (1 + \varepsilon) \|u - v\|^2 \quad \forall u, v \in S. \quad (2)$$

- Sean $X_1, \dots, X_n \sim \mathcal{N}(0, 1)$ i.i.d., $\mathbf{X} = (X_1, \dots, X_n)$ y $\mathbf{Y} = \frac{\mathbf{X}}{\|\mathbf{X}\|}$. Sea $\Psi = [\mathbf{I}_k, \mathbf{0}_{k \times (n-k)}] \in \mathbb{R}^{k \times n}$ con $\mathbf{I}_k \in \mathbb{R}^{k \times k}$ la identidad y $\mathbf{0}_{k \times (n-k)} \in \mathbb{R}^{k \times (n-k)}$ la matriz de ceros. Demuestre que

$$\mathbb{E}[\|\Psi \mathbf{Y}\|^2] = \frac{k}{n} \quad (3)$$

(Pista: Argumente que $X_1^2 \|\mathbf{X}\|^{-2}, \dots, X_n^2 \|\mathbf{X}\|^{-2}$ son idénticamente distribuidas y use linealidad de la esperanza.)

- Vamos a necesitar el siguiente resultado:

Lemma 2. *Sea $k < n$. Entonces,*

- Si $\beta < 1$

$$\Pr \left[\|\Psi \mathbf{Y}\|^2 \leq \beta \frac{k}{n} \right] \leq \exp \left(\frac{k}{2} (1 - \beta + \log \beta) \right) \quad (4)$$

- Si $\beta > 1$

$$\Pr \left[\|\Psi \mathbf{Y}\|^2 \geq \beta \frac{k}{n} \right] \leq \exp \left(\frac{k}{2} (1 - \beta + \log \beta) \right) \quad (5)$$

Suponga que $\beta < 1$.

- a) Demuestre que para $t > 0$

$$\Pr \left[\|\Psi \mathbf{Y}\|^2 \leq \beta \frac{k}{n} \right] = \Pr \left[\exp \left\{ t \left(k\beta \sum_{i=1}^n X_i^2 - n \sum_{i=1}^k X_i^2 \right) \right\} \geq 1 \right] \quad (6)$$

- b) Use la *desigualdad de Markov*¹ y el resultado previo para demostrar que,

$$\Pr \left[\|\Psi \mathbf{Y}\|^2 \leq \beta \frac{k}{n} \right] \leq \mathbb{E} \left[\exp \left\{ t \left(k\beta \sum_{i=1}^n X_i^2 - n \sum_{i=1}^k X_i^2 \right) \right\} \right] \quad (7)$$

¹https://en.wikipedia.org/wiki/Markov%27s_inequality

- c) Si X, Y son variables aleatorias independientes, entonces $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. Use este hecho y la función generadora de momentos de la distribución Chi-cuadrada² para demostrar que el lado derecho de (7) es igual a

$$g(t) = (1 - 2tk\beta)^{-(n-k)/2} (1 - 2t(k\beta - n))^{-k/2} \quad (8)$$

- d) Argumente que para que $g(t)$ tenga sentido necesitamos $t \in (0, (2k\beta)^{-1})$.
e) Demuestre que el minimizador de $g(t)$ sujeto a $t \in (0, (2k\beta)^{-1})$ está dado por $t_0 = (1 - \beta)(2\beta(n - k\beta))^{-1}$ (*Pista: Demuestre que puede maximizar $g(t)^{-2}$*).
f) Use el resultado anterior para demostrar que

$$\Pr \left[\|\Psi \mathbf{Y}\|^2 \leq \beta \frac{k}{n} \right] \beta^{k/2} \left(1 + \frac{k(1 - \beta)}{n - k} \right)^{(n-k)/2} \quad (9)$$

- g) Acote el lado derecho de (9) para recuperar (4) (*Pista: Si $t, x > 0$, $e^t \geq (1 + \frac{t}{x})^x$*).
h) Use el mismo procedimiento para demostrar (5).
i) Basado en este Lemma, es probable que $\|\Psi \mathbf{Y}\|^2$ estará lejos de su media?

3. (Ahora demostramos Lemma 1) Suponga que $n > k$ (en otro caso, terminamos). Sea $\Phi \in \mathbb{R}^{k \times n}$ una transformación lineal que proyecta \mathbb{R}^n a un subespacio aleatorio de \mathbb{R}^n de dimensión k . Use cualquier de los resultados anteriores para demostrar que:

$$\mathbb{E} [\|\Phi(\mathbf{u} - \mathbf{v})\|^2] = \frac{k}{n} \|\mathbf{u} - \mathbf{v}\|^2 \quad (10)$$

Argumente que el Lemma (2) puede ser usado en este caso.

4. Sea $\varepsilon \in (0, 1)$. Use el Lemma (2) para demostrar que para todo $\mathbf{u}, \mathbf{v} \in S$ con $\mathbf{u} \neq \mathbf{v}$,

$$\Pr \left[\|\Phi(\mathbf{u} - \mathbf{v})\|^2 \leq (1 - \varepsilon) \frac{k}{n} \|\mathbf{u} - \mathbf{v}\|^2 \right] \leq \exp \left(-k \frac{\varepsilon^2}{4} \right) \quad (11)$$

(*Pista: $\log(1 - x) \leq -x - x^2/2$ para todo $0 \leq x < 1$*).

5. Suponga que k satisface (1). Use (11) para demostrar que

$$\Pr \left[\|\Phi(\mathbf{u} - \mathbf{v})\|^2 \leq (1 - \varepsilon) \frac{k}{n} \|\mathbf{u} - \mathbf{v}\|^2 \right] \leq \frac{1}{m^2} \quad (12)$$

6. (Opcional) Siga el mismo razonamiento para demostrar que

$$\Pr \left[\|\Phi(\mathbf{u} - \mathbf{v})\|^2 \geq (1 + \varepsilon) \frac{k}{n} \|\mathbf{u} - \mathbf{v}\|^2 \right] \leq \frac{1}{m^2} \quad (13)$$

(*Pista: Use el Lemma 2 y que $\log(1 + x) \leq x - x^2/2 + x^3/3$*).

7. Use (12) y (13) para proponer una $f : \mathbb{R}^n \rightarrow \mathbb{R}^k$ tal que para $\mathbf{u}, \mathbf{v} \in S$ con $\mathbf{u} \neq \mathbf{v}$

$$\Pr \left[\frac{\|f(\mathbf{u}) - f(\mathbf{v})\|^2}{\|\mathbf{u} - \mathbf{v}\|^2} \notin [(1 - \varepsilon), (1 + \varepsilon)] \right] \leq \frac{2}{m^2} \quad (14)$$

8. Use la desigualdad de Boole³ para demostrar que

$$\Pr \left[\exists \mathbf{u}, \mathbf{v} \in S : \mathbf{u} \neq \mathbf{v} \text{ y } \frac{\|f(\mathbf{u}) - f(\mathbf{v})\|^2}{\|\mathbf{u} - \mathbf{v}\|^2} \notin [(1 - \varepsilon), (1 + \varepsilon)] \right] \leq 1 - \frac{1}{m}$$

Pista: Re-escriba el evento $\{\exists \mathbf{u}, \mathbf{v} \in S : \mathbf{u} \neq \mathbf{v} \text{ y } \frac{\|f(\mathbf{u}) - f(\mathbf{v})\|^2}{\|\mathbf{u} - \mathbf{v}\|^2} \notin [(1 - \varepsilon), (1 + \varepsilon)]\}$ como una unión de $\binom{m}{2}$ eventos.

9. ¿ El resultado anterior implica Lemma 1? (*Pista: Sí*)

²https://en.wikipedia.org/wiki/Moment-generating_function

³https://en.wikipedia.org/wiki/Boole%27s_inequality

2 Aplicación: Programación Lineal

Diseñe e implemente un experimento numérico para demostrar de manera empírica si el tiempo de ejecución de Programación Lineal mejora al reducir la dimensionalidad de los datos con el Lemma de Johnson-Lindenstrauss. Algunas sugerencias:

1. Considere problemas de la forma

$$\begin{array}{ll}\min & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq 0\end{array}\tag{15}$$

2. Resuelva con el solver GLPK de cvxopt <https://cvxopt.org/userguide/coneprog.html#optional-solvers>
3. Reduzca la dimensionalidad de los datos usando el *proyector de Achlioptas* $\mathbf{X} \in \mathbb{R}^{k \times m}$ con entradas tal que $\Pr[\mathbf{X}_{i,j} = +1] = \Pr[\mathbf{X}_{i,j} = -1] = \frac{1}{6}$ y $\Pr[\mathbf{X}_{i,j} = 0] = \frac{2}{3}$.
4. Use $k = \frac{1.8}{\varepsilon^2} \log m$, $\varepsilon = 0.2$.